FaceMocap

Antonino Di Gregorio*, Federico Monetti†
*s328228@studenti.polito.it
†s361062@studenti.polito.it

I. Introduzione

Il motion capture (mocap) rappresenta l'acquisizione e la registrazione del movimento di esseri umani, animali e oggetti inanimati. I dati acquisiti possono essere successivamente elaborati e utilizzati per riprodurre il movimento di modelli tridimensionali mediante l'uso di opportune strutture dati. I sistemi tradizionali di motion capture richiedono attrezzature costose e di elevata complessità tecnologica. Tali fattori hanno limitato l'accessibilità a un pubblico general consumer, favorendone l'impiego principalmente in ambiti quali l'industria videoludica, quella cinematografica e la ricerca scientifica.

Negli ultimi anni, il miglioramento delle capacità computazionali dei processori (CPU), la diffusione di acceleratori hardware per il calcolo parallelo, quali le General-Purpose Graphics Process Unit (GPGPU) e le Neural Processing Unit (NPU), e i progressi nell'ambito dell'intelligenza artificiale, in particolar modo sulle tecniche di machine learning. Hanno permesso la realizzazione di modelli neurali usati nella computer vision, capaci di effettuare delle stime del moto attraverso risorse di acquisizione più limitate, comportando un costo computazionale più oneroso.

In questo contesto, l'obiettivo di questa tesina è esplorare l'uso di tecniche di machine learning per realizzare un sistema di facial motion capture senza l'uso di marker facciali, basato sull'acquisizione delle immagini mediante un'unica webcam. A tale scopo, viene sviluppato un add-on in Blender, per integrare il sistema all'interno di una pipeline di animazione 3D. Valutando la sua efficacia per poter ad esempio realizzare animazioni facciali e semplificare la creazione di shape key per l'animazione di un personaggio umanoide.

II. Related works

Nel corso degli anni sono stati sviluppati diversi sistemi di motion capture categorizzabili in quattro principali gruppi: ottici, magnetici, meccanici e inerziali. Segue una breve descrizione dei vari sistemi con un approfondimento sui sistemi ottici in quanto maggiormente diffusi e principalmente usati per il facial motion capture.

A. Sistemi Inerziali

I sistemi inerziali non utilizzano videocamere per acquisire il movimento, ma si basano principalmente su sensori inerziali, quali accelerometri e giroscopi, che misurano rispettivamente l'accelerazione lineare e la velocità angolare. L'integrazione nel tempo della velocità angolare misurata dal giroscopio fornisce una stima della variazione dell'orientamento del sensore rispetto al suo orientamento iniziale nel suo sistema di riferimento locale. Tale stima è tuttavia soggetta a deriva nel tempo, dovuta ai limiti intrinseci del giroscopio, a causa delle caratteristiche non ideali dei suoi componenti.

Gli accelerometri forniscono informazioni sulla direzione della gravità, e anche sull'accelerazione del moto della parte del corpo in cui il sensore si trova. L'accelerazione gravitazionale misurata dal sensore viene utilizzata per stimare l'up direction (pitch e roll) del sensore rispetto al sistema di riferimento globale. Tuttavia, le misure di accelerazione possono essere corrotte da rumore ad alta frequenza dovuto a un rapido movimento del sensore.

Per ottenere un riferimento anche per la componente di yaw, dei magnetometri vengono integrati per misurare l'intensità del campo magnetico, consentendo di stimare l'orientamento rispetto al campo

magnetico terrestre. Tale misura può tuttavia essere influenzata da interferenze magnetiche provenienti dall'ambiente circostante.

Le informazioni provenienti dai diversi sensori vengono combinate mediante algoritmi di sensor fusion, con l'obiettivo di ottenere una stima più robusta dell'orientamento e di mitigare gli effetti della deriva del giroscopio e delle perturbazioni presenti nelle misure degli altri sensori. I dati catturati vengono trasmessi via wireless ad un computer, dove possono essere ulteriormente elaborati. [1]



Fig. 1: Esempio di sensore inerziale usato nella Smartsuit Pro II distribuita da Rokoko

B. Sistemi magnetici

I sistemi di motion capture magnetici sono costituiti da uno o più trasmettitori e una serie di sensori, ossia dei ricevitori, piazzati sull'attore e connessi via cavo a un'unità di controllo.

Quindi un tracker magnetico comprende un trasmettitore, un insieme di sensori che varia da 11 a 18, un'unità di controllo e il software.

In particolare, il trasmettitore genera un campo elettromagnetico a bassa frequenza che viene rilevato dai ricevitori e dato in input all'unità di controllo, dove questo viene filtrato e amplificato. Successivamente, i dati acquisiti vengono inviati a un computer che, attraverso un opportuno software, ricava la posizione e l'orientamento di ciascun sensore.

I sistemi magnetici possono essere distinti in sistemi che usano campi elettromagnetici generati da una corrente continua (DC) e sistemi che usano campi generati da una corrente alternata (AC).

Tuttavia, entrambi i sistemi sono sensibili alle interferenze dovute alla "conduttività metallica". In particolare, i sistemi DC sono sensibili ai materiali ferromagnetici che possono alterare il campo magnetico generato dal trasmettitore. Mentre i sistemi AC sono sensibili ai materiali conduttori, come all'alluminio e al rame, che possono generare correnti indotte in presenza di un campo magnetico variabile. Queste correnti producono a loro volta campi elettromagnetici che alterano il campo rilevato dai sensori, introducendo errori nella stima della posizione e dell'orientamento.

Questi sistemi vengono generalmente impiegati per applicazioni real-time, in quanto permettono di raggiungere un campionamento di 144 a 240 sample al secondo. [2]

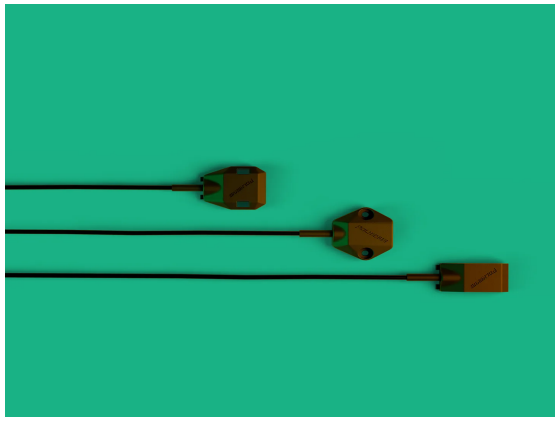


Fig. 2: Esempio di sensore magnetico per i sistemi elettromagnetici AC e prodotto da Polhemus

C. Sistemi meccanici

I sistemi di motion capture meccanici si basano sull'utilizzo di un esoscheletro indossabile costituito da link cinematici, ossia delle aste rigide. Questi ultimi sono collegati attraverso dei potenziometri alle giunture del corpo umano, che consentono di misurare l'angolo di flessione ed estensione articolare. Tali sistemi permettono l'acquisizione del movimento in real-time, e non sono soggetti alle occlusioni e alle interferenze magnetiche ed elettriche. Tuttavia, presentano limitazioni legate alla scarsa ergonomicità dell'esoscheletro che limitano la libertà di movimento dell'attore. Inoltre, non sono in grado di misurare la global translation accuratamente, che viene stimata mediante l'integrazione di accelerometri la cui misura risulta comunque soggetta a errori di deriva. [3]



Fig. 3: Esempio esoscheletro per il motion capture meccanico: GYPSY7

D. Sistemi Ottici

I sistemi ottici utilizzano telecamere speciali e marker posizionati sull'attore. Sono stati sviluppati anche sistemi di tipo markerless. In particolare, i marker possono essere passivi o attivi.

Marker passivi: sono realizzati attraverso un materiale riflettente e presentano una forma sferica, oppure semisferica o circolare e la loro dimensione dipende dalla risoluzione delle camere utilizzate e dal tipo di soggetto che si vuole catturare. In questo caso vengono utilizzate telecamere composte da LED, quindi i marker possono essere individuati riflettendo la luce emessa dalla camera. Tuttavia, in questi sistemi, la luce ambientale presente nel set gioca un ruolo fondamentale.



(a) Esempio di Vicom camera con i LED, usata in concomitanza con i marker passivi



(b) Esempio di marker passivo prodotto da Qualisis

Marker attivi: sono dei LED che emettono luce ad una specifica frequenza e intensità per facilitare la loro tracciamento.

In particolare, il facial motion capture può essere realizzato usando dei marker di 2 o 3 mm di diametro applicati sul viso del soggetto da catturare. Solitamente le espressioni vengono catturate separatamente rispetto al resto del corpo, usando una camera solidale al viso del soggetto. In questo modo è possibile rimuovere dai dati registrati il movimento della testa, catturando quindi unicamente gli spostamenti locali del viso. Infine i dati catturati vengono utilizzati per generare il facial rig.

Ma tuttora vengono utilizzati dei sistemi markerless sia per la cattura del movimento del corpo dell'attore che delle espressioni facciali. I sistemi Markerless sfruttano il machine learning e per ricostruire e tracciare il corpo direttamente dai frame video.

Ad oggi è stato studiato, nell'analisi del controllo posturale in stazione eretta, come i sistemi che non utilizzano marker(in particolare sistemi Theia3D™) siano valide alternative, con il vantaggio di permettere un tracking del movimento non invasivo, ottenendo quindi risultati comparabili ma non completamente sostituibili, ai sistemi con marker(in particolare sistemi Vicon™), che risultano essere attualmente più accurati e meno sensibili al rumore. [4]

È stata anche eseguita un'analisi su 22 studi diversi che confrontano sistemi markerless camera-based e sistemi a marker nell'analisi del cammino (gait analysis). È stato ottenuto come risultato che per alcune articolazioni degli arti inferiori, come quella della caviglia, i sistemi markerless possiedono poca affidabilità e accuratezza, mentre per ginocchia e anca i risultati sono stati quasi comparabili tra sistemi con e senza marker. [5]

Sebbene questi studi riguardino il tracciamento dell'intero corpo e non specificamente il volto, i risultati sono rilevanti perché la domanda — se il markerless raggiunga la stessa affidabilità dei sistemi a marker — è la stessa che si pone per il facial mocap markerless discusso in questa relazione.

Un esempio rilevante di come l'intelligenza artificiale sia stata applicata per diminuire il divario qualitativo tra i complessi sistemi di produzione e le soluzioni markerless a singola telecamera è il lavoro presentato da Laine et al. (2017) [6]. In questo studio, i ricercatori hanno sviluppato un framework basato su reti neurali CNN, capace di dedurre il tracciamento denso in 3D del volto (circa 5000 vertici) a partire da un video monoculare. Il loro approccio prevede una prima fase in cui vengono registrati dai 5 ai 10 minuti di video utilizzando una costosa pipeline di cattura multi-vista a 9 telecamere, per poi usare questi dati per addestrare la rete neurale. Una volta addestrata, la rete è in grado di elaborare video in tempo reale (da 287 fino a 870 FPS) usando solo l'output di una singola telecamera, riuscendo a gestire in modo plausibile anche aree complesse e soggette a occlusioni come le labbra e gli occhi. Tuttavia, come evidenziato dagli stessi autori, il limite principale di questo sistema altamente accurato è la necessità di una calibrazione, ovvero la rete neurale deve essere riaddestrata da zero per ogni nuovo attore, rendendo il processo vincolato al singolo volto.

È in questo contesto di ricerca di un sistema in tempo reale, accurato ma totalmente generalizzato (che non richieda addestramenti specifici per l'utente), che si inserisce l'approccio alla base del nostro progetto. Il sistema di tracciamento facciale utilizzato da FaceMocap è MediaPipe Face Mesh, basato sul lavoro di Kartynnik et al. (2019) [7], sviluppato dal team Google Research responsabile della libreria. Viene

utilizzata una rete neurale capace di ottenere una mesh approssimata della superficie del volto con 468 landmark, partendo da un frame RGB di una semplice webcam. Progettato per l'utilizzo su GPU mobile, garantisce una velocità tra i 100 e i 1000 FPS, in base al dispositivo utilizzato.

III. Approccio applicato

A. *Modello 3D di riferimento*

Per l'applicazione degli algoritmi di motion capture da noi sviluppati si è preferito modellare un volto con una topologia per quanto possibile pulita ed adatta per le animazioni facciali prendendo come riferimento le tecniche e considerazioni da "The Pushing Points Topology" [8] [9]

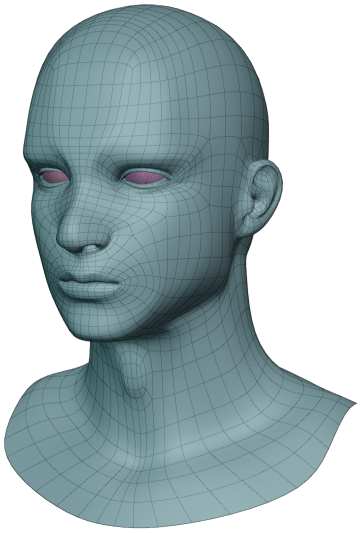


Fig. 5: Face model reference

B. *Rigging*

Si è scelto di sviluppare due differenti configurazioni di rigging, denominate *base rig* e *advance rig*.

Il *base rig* viene utilizzato per valutare possibili imperfezioni nella topologia del modello, predisporre una struttura di partenza per la creazione delle blend shape o per realizzare animazioni facciali prototipali utili alla realizzazione dell'animatic, ossia una versione animata di uno storyboard.

L'*advance rig* si basa sulla realizzazione di un *landmarker set rig*, chiamato anche source rig, che rappresenta i landmarker individuati da MediaPipe che verranno piazzati sul modello. Permettendo all'utente di visualizzare i landmark durante l'acquisizione video. Le trasformazioni delle ossa del *source rig* vengono utilizzate per pilotare un sottoinsieme del *target rig*, che costituisce la struttura destinata all'animazione del modello facciale.

Abbiamo creato appositamente un target rig per l'animazione facciale, prendendo come riferimento il rigging facciale realizzato da Blender Studio per Storm project [10] [11]. Questo ci permette di valutare l'efficacia del nostro approccio applicato a un rig avanzato usato dagli animatori in una pipeline di produzione.

C. *Modello di tracciamento*

Il tracciamento dei landmark facciali è affidato a MediaPipe Face Mesh, un modello neurale preaddestrato che, partendo da un singolo frame RGB catturato da una webcam, restituisce in tempo reale le coordinate tridimensionali di massimo 468 punti di riferimento distribuiti sulla superficie del volto. Il modello viene utilizzato senza alcuna fase di addestramento o calibrazione specifica per l'utente: l'unica

fase preliminare richiesta da FaceMocap è una breve calibrazione di circa 30 frame a viso fermo in posa neutra, utilizzata non per addestrare il modello ma per stimare il fattore di scala fra lo spazio dei landmark (normalizzato, adimensionale) e lo spazio dell'armatura di Blender, e per registrare l'orientamento di riferimento della testa. Da questo insieme di 468 punti, FaceMocap seleziona un sottoinsieme ridotto di landmark, ciascuno associato a un osso specifico dell'armatura tramite una tabella di corrispondenza (`FACE_MAPPING`), definisce le relazioni di parentela e la posizione di riposo.

D. ***Struttura del Base rig***

L'armatura generata da FaceMocap è organizzata gerarchicamente, con un osso radice (Head) da cui discendono tutte le altre ossa, raggruppate per regione anatomica. Ogni osso è associato, in fase di generazione dell'armatura, sia a una posizione di ancoraggio sul landmark MediaPipe corrispondente, impiegata dal solutore per stimare le scale di conversione, sia a una geometria (posizione della testa e della coda dell'osso) orientata verso l'interno del volume della mesh, per un'assegnazione dei pesi di deformazione (bone heat) coerente e localizzata, evitando che il movimento di un osso influenzi porzioni della mesh appartenenti ad altre regioni del volto.

E. ***Parentela e propagazione del movimento***

La quasi totalità delle ossa facciali è figlia diretta di Head e viene mossa per traslazione: lo spostamento del landmark corrispondente, calcolato rispetto alla posa neutra e convertito dallo spazio dei landmark allo spazio dell'armatura, viene applicato direttamente come location dell'osso in Pose Mode.

Fa eccezione la mandibola. Jaw è figlia di Head ma viene mossa per rotazione attorno a un perno anziché per traslazione, in analogia con l'articolazione temporo-mandibolare reale: il movimento del mento (dedotto dal landmark corrispondente) viene convertito in un angolo di apertura, applicato come rotazione dell'osso attorno al proprio perno. Le ossa figlie di Jaw, labbro inferiore e gli angoli della bocca, ereditano quindi il movimento del genitore per composizione delle trasformazioni: alla rotazione ereditata da Jaw si somma uno spostamento residuo proprio di ciascun osso, necessario a riprodurre movimenti del labbro non interamente spiegabili dalla sola apertura della mandibola (ad esempio un sorriso o un broncio). Il calcolo corretto di questo residuo, in presenza di un genitore che ruota anziché traslare, richiede di scomporre il movimento osservato del landmark nella componente già spiegata dalla rotazione del genitore e nella componente eccedente, da applicare come trasformazione locale dell'osso figlio.

F. ***Utilizzo di un advance rig***

1) ***Source rig****:* L'add-on permette la creazione di un *source rig* che si compone di un insieme di 60 ossa, ciascuna associata a uno dei landmark individuati da mediapipe. Le ossa del *source rig* vengono utilizzate per ricavare le trasformazioni necessarie per traslare e ruotare opportunamente le ossa del *target rig* durante il processo di retargeting. Per alcune ossa di controllo, il cui movimento deve essere rappresentato esclusivamente mediante rotazioni, viene definito un sistema di riferimento locale, detto *local frame*. Ciò permette di rappresentare correttamente il movimento di specifiche parti del volto, come ad esempio la rotazione della mandibola e del collo.

2) ***Target rig****:* Il *target rig* è stato progettato per rappresentare un possibile rig impiegabile in una pipeline di produzione. Pertanto presenta 259 ossa ed è strutturato in modo da consentire l'animazione di un volto umano senza ricorrere all'uso di *blendshape*. Il rig si compone di diversi livelli gerarchici e differenti tipologie di ossa. Ai fini del retargeting, è risultato utile pilotare solo un sottoinsieme di queste ossa, costituito dalle ossa di controllo locali per le labbra, gli occhi, le ciglia e le sopracciglia, dalle ossa di deformazione per il collo e la testa, e dalle ossa dedicate al movimento oculare, ottenendo un totale di 25 *target bone* per animare il nostro modello.

In particolare, ciascun osso di controllo locale definisce una regione del volto all'interno della quale viene applicato il movimento. La distribuzione delle deformazioni tra le ossa di controllo segue il *3 curve*

principle [12], secondo il quale la distribuzione dei pesi associata a un controllo può essere suddivisa in tre distribuzioni distinte, ciascuna associata a un diverso controllo. La combinazione di queste distribuzioni consente di ricostruire la distribuzione dei pesi originale, mantenendo la continuità della deformazione. Questa tecnica permette di ottenere un controllo localizzato e articolato del movimento, particolarmente utile per l'animazione delle labbra, delle palpebre e delle sopracciglia. Inoltre, per limitare gli effetti del rumore dovuto alle trasformazioni derivate dai landmark, vengono applicati dei vincoli sulla posizione massima e minima che le *target bone* possono assumere.

Il binding tra il *source rig* e il *target rig* realizzato mediante la classe `RetargetMap`, che permette di definire un ruolo che specifica una relazione tra l'osso target e le ossa del source rig. La configurazione può essere modificata dall'utente specificando il tipo di trasformazione da trasferire al target bone e il relativo fattore di gain da applicare al movimento.

Il retargeting del movimento tra il *source rig* e del *target rig* viene realizzato sfruttando gli stessi algoritmi utilizzati per l'animazione del *base rig*.

G. *Filtraggio del rumore*

L'output grezzo di MediaPipe Face Mesh, elaborato frame per frame senza alcuna informazione sulla storia recente del segnale, presenta un tremolio ad alta frequenza e bassa ampiezza anche in condizioni di viso perfettamente fermo. Sono state quindi sviluppate e confrontate due modalità di filtraggio del rumore:

1) Media mobile esponenziale (EMA): La prima versione di FaceMocap applicava alla posizione finale di ciascun osso una media mobile esponenziale

$$y[n] = (1 - \alpha) \cdot y[n-1] + \alpha \cdot x[n] \tag{1}$$

Con il parametro α costante per tutte le ossa, un'interpolazione lineare sferica per le ossa in rotazione, e un'interpolazione lineare per le ossa mosse per traslazione. Avere un α fisso però porta a non differenziare i movimenti dovuti al rumore rispetto a quelli intenzionali, dovendo quindi rappresentare un compromesso per entrambi i casi. Un α basso riduce notevolmente il rumore, introducendo però un ritardo significativo nei movimenti rapidi. Al contrario, aumentare il valore di α reintroduce il tremolio dovuto al rumore, essendo però più affidabile nella rappresentazione del movimento in tempo reale. Sono state eseguite diverse prove che hanno portato alla conclusione che non esiste un valore per un unico parametro che possa soddisfare contemporaneamente entrambe le esigenze.

2) Filtro One Euro: Per ottenere il risultato voluto, come proposto da *Casiez, Roussel e Vogel (2012)* [13] e citato da *Kartynnik et al., 2019* [7] durante lo sviluppo di MediaPipe Face Mesh, è stato adottato il filtro One Euro(1€ filter), specifico per il filtraggio di segnali rumorosi in sistemi interattivi in tempo reale. A differenza del filtro EMA, il filtro One Euro utilizza un filtro passa-basso del primo ordine con una frequenza di taglio non costante, ma dipendente dalla velocità istantanea del segnale, stimata a sua volta tramite un altro filtro passa-basso applicato alla derivata del segnale

$$f_c(v) = f_{c,min} + \beta \cdot |v| \tag{2}$$

Quando il segnale è fermo, la velocità stimata è vicina a zero e la frequenza di taglio è bassa, garantendo uno smoothing efficace. Quando invece il segnale accelera, la frequenza di taglio cresce proporzionalmente riducendo il ritardo introdotto dal filtro rendendolo trascurabile nei movimenti rapidi Il filtro richiede quindi il solo tuning di due parametri, min_cutoff e β: il primo regola lo smoothing a riposo, il secondo la reattività ai movimenti rapidi.

IV. Risultati

V. Conclusione

Il lavoro presentato in questa tesina ha dimostrato la fattibilità e l'efficacia di FaceMocap, un sistema di facial motion capture markerless, integrato all'interno di Blender tramite un add-on dedicato. Sfruttando

le potenzialità di MediaPipe Face Mesh, è stato possibile evitare le necessità di hardware dedicato dei sistemi tradizionali con marker, ottenendo un tracciamento facciale in tempo reale a partire da un singolo flusso video senza la necessità che l'utente debba addestrare un modello di riconoscimento. L'architettura sviluppata ha permesso di validare l'approccio su due differenti livelli di complessità all'interno della pipeline di produzione 3D:

- *Prototipazione rapida (Base Rig)*: La generazione automatica dell'armatura, unita alla scomposizione cinematica tra la rotazione a leva dell'articolazione temporo-mandibolare (Jaw) e le traslazioni di labbra e sopracciglia, si è rivelata uno strumento immediato per il test topologico delle mesh.
- *Integrazione in produzione (Advanced Rig)*: Il sistema di retargeting tramite Source Rig (60 ossa) e RetargetMap ha dimostrato una buona flessibilità nel pilotare un Target Rig complesso (259 ossa strutturate secondo il 3 curve principle), per adattare l'add-on agli standard richiesti dalle animazioni più complesse.

Un risultato determinante ai fini dell'usabilità del sistema è stato ottenuto nell'ambito del filtraggio del segnale. Il passaggio da una media mobile esponenziale (EMA) a parametro α fisso al Filtro One Euro (1€ filter) ha risolto il classico compromesso tra jitter e latenza. La frequenza di taglio adattiva basata sulla velocità della derivata ha permesso di stabilizzare efficacemente la posa plastica a riposo, preservando al contempo la reattività necessaria per catturare micro-espressioni rapide come l'ammiccamento delle palpebre o i movimenti labiali durante il parlato.

A. Limitazioni attuali e Sviluppi Futuri

Nonostante i risultati siano soddisfacenti, il sistema presenta delle limitazioni intrinseche dovute alla natura a singola camera dell'acquisizione e al modello di tracciamento:

- Stima della profondità e occlusioni: L'utilizzo di una singola webcam rende la stima lungo la profondità (asse Z della camera) complessa, oltre a soffrire di perdita di tracciamento in presenza di rotazioni estreme della testa o auto-occlusioni (es. mani davanti al volto).
- Espressività complessa: Movimenti molto sottili o non pienamente catturati dalla topologia dei 468 landmark di MediaPipe (come il movimento della lingua, la contrazione della fronte o il rigonfiamento delle guance) risultano difficili da trasferire fedelmente col solo calcolo geometrico.

Alla luce di queste considerazioni, possibili sviluppi futuri per FaceMocap includono:

- Registrazione sulla Timeline di Blender: Implementazione di un sistema per registrare in tempo reale le trasformazioni come keyframe all'interno di Blender, permettendo agli animatori di rifinire manualmente l'animazione catturata.
- Integrazione delle Blendshapes di MediaPipe: Sfruttare i coefficienti di blendshape (standard ARKit) forniti dalle recenti API di MediaPipe (FaceLandmarker) in affiancamento al tracciamento geometrico dei landmark, per pilotare direttamente shape key correttive o espressioni facciali più complesse.
- Calibrazione dinamica del Range of Motion (ROM): Sviluppare una procedura di calibrazione che, oltre alla posa neutra, registri le espressioni estreme dell'utente (massima apertura boccale, massimo innalzamento sopracciglia) per normalizzare automaticamente i fattori di gain in base alla fisionomia specifica dell'attore.
- Completa modularità per l'utilizzo di qualsiasi modello facciale con la relativa armatura.

REFERENCES

[1] B. R. Hindle, J. W. L. Keogh, and A. V. Lorimer, "Inertial-based human motion capture: A technical summary of current processing methodologies for spatiotemporal and kinematic measures," *Applied Bionics and Biomechanics*, vol. 2021, no. 1, p. 6628320, 2021. [Online]. Available: https://onlinelibrary.wiley.com/doi/abs/10.1155/2021/6628320

[2] A. Menache, "1 - motion capture primer," in *Understanding Motion Capture for Computer Animation (Second Edition)*, second edition ed., ser. The Morgan Kaufmann Series in Computer Graphics. Boston: Morgan Kaufmann, 2011, pp. 1–46. [Online]. Available: https://www.sciencedirect.com/science/article/pii/B9780123814968000019

[3] M. Kitagawa and B. Windsor, *MoCap for Artists: Workflow and Techniques for Motion Capture*. Amsterdam ; Boston: Focal Press, 2008. [Online]. Available: https://www.taylorfrancis.com/books/mono/10.4324/9780080877945/mocap-artists-midori-kitagawa-brian-windsor

[4] P. Federolf, M. Kühne, K. Schiel, E. Reimeir, D. Debertin, M. Calisti, and M. Mohr, "Validation of markerless (theia3d™) against marker-based (vicon™) motion capture data of postural control movements analyzed through principal component analysis," *Journal of Biomechanics*, vol. 189, p. 112831, 2025. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S0021929025003434

[5] S. Scataglini, E. Abts, C. Van Bocxlaer, M. Van den Bussche, S. Meletani, and S. Truijen, "Accuracy, validity, and reliability of markerless camera-based 3d motion capture systems versus marker-based 3d motion capture systems in gait analysis: A systematic review and meta-analysis," *Sensors*, vol. 24, no. 11, 2024. [Online]. Available: https://www.mdpi.com/1424-8220/24/11/3686

[6] S. Laine, T. Karras, T. Aila, A. Herva, S. Saito, R. Yu, H. Li, and J. Lehtinen, "Production-level facial performance capture using deep convolutional neural networks," 2017. [Online]. Available: https://arxiv.org/abs/1609.06536

[7] Y. Kartynnik, A. Ablavatski, I. Grishchenko, and M. Grundmann, "Real-time facial surface geometry from monocular video on mobile gpus," *arXiv preprint arXiv:1907.06724*, 2019.

[8] W. C. Vaughan, *The Pushing Points Topology Workbook: Volume 01*. North Charleston, SC: CreateSpace Independent Publishing Platform, 2018.

[9] ——, *The Pushing Points Topology Workbook: Volume 02*. Pushing Points, September 2019. [Online]. Available: http://pushingpoints.com/v2/the-pushing-points-topology-workbook-volume-2/

[10] Blender Studio, "Storm Project," https://studio.blender.org/blog/storm-has-been-released/.

[11] ——, "Introducing Storm - High-quality Blender 5.0 character rig," https://www.youtube.com/watch?v=5rSYsMMOCmI.

[12] B. Tindall, *The Art of Moving Points*. Hippydrome Publishing, apr 2013.

[13] G. Casiez, N. Roussel, and D. Vogel, "1 € filter: a simple speed-based low-pass filter for noisy input in interactive systems," in *Proceedings of the SIGCHI Conference on Human Factors in Computing Systems*, ser. CHI '12. New York, NY, USA: Association for Computing Machinery, 2012, p. 2527–2530. [Online]. Available: https://doi.org/10.1145/2207676.2208639